

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN, ĐHQG-HCM
KHOA CÔNG NGHỆ THÔNG TIN



KHÓA LUẬN TỐT NGHIỆP

NGHIÊN CỨU PHƯƠNG PHÁP XÂY DỰNG NEOBERT CHO TIẾNG VIỆT

Giảng viên hướng dẫn

TS. Nguyễn Hồng Bửu Long
TS. Lương An Vinh

Sinh viên thực hiện

Bùi Khắc Trung – 22120396
Trần Anh Tú – 22120400

Tp. Hồ Chí Minh, tháng 07 năm 2026

1. Giới thiệu
2. Cơ sở lý thuyết
3. Phương pháp đề xuất
 - 3.1 Tổng quan
 - 3.2 Tập điểm neo
 - 3.3 Khởi tạo SALT
 - 3.4 Huấn luyện
4. Thực nghiệm và đánh giá
 - 4.1 Thiết lập
 - 4.2 So sánh khởi tạo
 - 4.3 Kết quả mô hình
5. Kết luận và hướng phát triển

Câu hỏi của khóa luận


Làm sao chuyển một mô hình
Encoder thể hệ mới sang tiếng Việt
mà không huấn luyện lại từ đầu?

Encoder-only là gì?

- ▶ Đọc câu theo *cả hai chiều*, sinh ra biểu diễn ngữ nghĩa cho từng từ – không sinh văn bản.
- ▶ Là lựa chọn mặc định cho phân loại văn bản, gán nhãn, hỏi đáp trích xuất, tìm kiếm ngữ nghĩa.
- ▶ BERT và RoBERTa vẫn đang được dùng rộng rãi trong thực tế.

Vấn đề

Trong khi các mô hình sinh văn bản (LLM) tiến hóa liên tục, các mô hình dòng Encoder-only đã *chững lại nhiều năm*, chỉ được cập nhật tiếp từ cuối năm 2024.



NeoBERT [Le Breton et al., 2025] đưa các cải tiến của thể hệ LLM trở lại kiến trúc Encoder:

- ▶ **RoPE** – mã hóa vị trí bằng phép quay
- ▶ **SwiGLU** – mạng truyền thẳng có cổng
- ▶ **Pre-RMSNorm** – chuẩn hóa trước mỗi lớp con
- ▶ **Sâu mà hẹp** – 28 lớp, kích thước ẩn 768

Chỉ **250 triệu tham số** nhưng vượt BERT_{large} và RoBERTa_{large} trên chuẩn đánh giá MTEB, đồng thời hỗ trợ ngữ cảnh **4.096 token** – gấp 8 lần BERT.

Cấu hình NeoBERT

Số lớp / kích thước ẩn	28 / 768
Tham số	≈ 250 triệu
Mã hóa vị trí	RoPE
Kích hoạt FFN	SwiGLU
Chuẩn hóa	Pre-RMSNorm
Ngữ cảnh tối đa	4.096 token
Dữ liệu tiền huấn luyện	2,1 nghìn tỷ token
Ngôn ngữ	chỉ tiếng Anh

Bảng cấu hình theo Le Breton et al. [2025]

Ba trở ngại

1. Encoder tiếng Việt hiện có (PhoBERT [Nguyen and Nguyen, 2020], ViDeBERTa [Tran et al., 2023]) dùng kiến trúc cũ, giới hạn 512 token.
2. Huấn luyện lại từ đầu cần **2,1 nghìn tỷ token** – bất khả thi với nhóm nghiên cứu nhỏ.
3. Thay lớp véc-tơ rồi huấn luyện tiếp một cách ngây thơ dễ gây **mất thông tin** (*catastrophic forgetting*).

Ý tưởng của khóa luận

Tái sử dụng thay vì huấn luyện lại

Giữ nguyên *phần thân* NeoBERT đã học từ tiếng Anh; chỉ thay lớp từ vựng, và khởi tạo lớp mới bằng cách *mượn* không gian ngữ nghĩa tiếng Việt sẵn có của ViDeBERTa.

Mục tiêu cụ thể

- ▶ Xây dựng **ViNeoBERT** bằng kỹ thuật SALT [Lee et al., 2025] có cải tiến.
- ▶ Chứng minh bằng thực nghiệm rằng cách này *tiết kiệm hơn nhiều* so với huấn luyện lại.

1. Giới thiệu
2. Cơ sở lý thuyết
3. Phương pháp đề xuất
4. Thực nghiệm và đánh giá
5. Kết luận và hướng phát triển

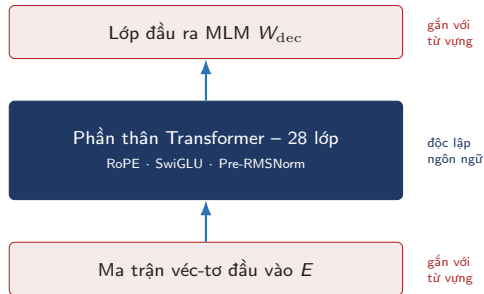
Cách Encoder được huấn luyện

Mô hình học bằng **mô hình hóa ngôn ngữ có mặt nạ** (*Masked Language Modeling*):
che ngẫu nhiên một số token rồi bắt mô hình đoán lại token gốc dựa vào ngữ cảnh hai bên
[Devlin et al., 2019].

Quan sát then chốt của khóa luận

- ▶ *Phần thân* Transformer học quy luật ngôn ngữ tổng quát – đây là phần **tốt nhất** khi huấn luyện.
- ▶ Chỉ *lớp véc-tơ đầu vào* và *lớp đầu ra* là gắn trực tiếp với bộ từ vựng của một ngôn ngữ.

⇒ Về nguyên tắc, đổi ngôn ngữ chỉ cần thay **hai lớp** này.



Phần đỏ phải thay khi chuyển sang tiếng Việt; phần navy được giữ nguyên

Thành phần	BERT	NeoBERT
Mã hóa vị trí	Bảng véc-tơ vị trí tuyệt đối, cộng vào đầu vào	RoPE : quay véc-tơ theo vị trí, đặt bên trong mỗi lớp [Su et al., 2024]
Kích hoạt FFN	GELU, mọi chiều qua cùng một phi tuyến	SwiGLU : thêm nhánh cổng chọn lọc thông tin [Shazeer, 2020]
Chuẩn hóa	LayerNorm đặt <i>sau</i> lớp con	Pre-RMSNorm : chuẩn hóa theo độ lớn, đặt <i>trước</i> [Zhang and Sennrich, 2019]
Hình dạng	12 lớp $\times$ 768 (ngô, rộng)	28 lớp $\times$ 768 – sâu mà hẹp [Levine et al., 2020]

Vì sao điều này quan trọng với đề tài

Bốn thay đổi trên nằm *toàn bộ* trong phần thân. Chúng làm phần thân mạnh hơn – và vì thế đáng để giữ lại – nhưng cũng đặt ra hai ràng buộc cho việc thay lớp từ vựng, trình bày ở slide sau.

1. RoPE – thuận lợi

Điểm chú ý giữa hai token chỉ phụ thuộc *khoảng cách* $m - n$:

$$q_m^\top k_n = x_m^\top W_q^\top R_{\Theta, n-m} W_k x_n$$

- ▶ Thông tin vị trí **không nằm** trong ma trận véc-tơ.

⇒ Thay toàn bộ lớp từ vựng tiếng Việt *không đụng chạm* cơ chế vị trí.

2. Pre-RMSNorm – ràng buộc

Chuẩn hóa chia theo độ lớn véc-tơ:

$$\bar{a}_i = \frac{a_i}{\text{RMS}(a)} g_i$$

- ▶ Lớp véc-tơ đi thẳng vào luồng chính qua kết nối tắt.
- ⇒ Nếu **độ lớn** véc-tơ mới lệch khỏi thống kê của NeoBERT, sai lệch bị khuếch đại qua 28 lớp.

3. Lớp đầu ra không dùng chung trọng số


Khác BERT/RoBERTa, đầu MLM của NeoBERT là một ma trận *độc lập* với ma trận véc-tơ đầu vào. Vì vậy chuyển sang tiếng Việt phải khởi tạo **cả hai ma trận**, mỗi ma trận trong đúng không gian của nó.

Khởi tạo ngẫu nhiên là lựa chọn tồi

Phần thân buộc phải học lại từ tín hiệu đầu vào vô nghĩa, dễ phá vỡ biểu diễn đã có [de Vries and Nissim, 2021].

Hướng khắc phục: khởi tạo token mới bằng *thông tin ngữ nghĩa đã biết* – WECHSEL [Minixhofer et al., 2022], FOCUS [Dobler and de Melo, 2023], OFA [Liu et al., 2024].

SALT [Lee et al., 2025] đi xa hơn: tái sử dụng trực tiếp không gian véc-tơ của một mô hình *đã tiền huấn luyện* ở ngôn ngữ đích, qua các ánh xạ tuyến tính *cục bộ* theo từng token.



Hạn chế với cặp Anh–Việt

SALT gốc chỉ lấy điểm neo là các token *trùng mặt chữ*. Anh và Việt khác nhau lớn về hình thái $\Rightarrow$ rất ít điểm neo, độ phủ ngữ nghĩa hẹp.

1. Giới thiệu

2. Cơ sở lý thuyết

3. Phương pháp đề xuất

3.1 Tổng quan


3.2 Tập điểm neo

3.3 Khởi tạo SALT

3.4 Huấn luyện

4. Thực nghiệm và đánh giá

5. Kết luận và hướng phát triển



Ba cải tiến của khóa luận so với SALT gốc

1. **Mở rộng tập điểm neo** bằng các cặp dịch Anh–Việt khai thác tự động.
2. **Khởi tạo riêng lớp đầu ra**, kèm hệ số điều chỉnh theo tần suất token và hệ số tỉ lệ γ .
3. **Bổ sung giai đoạn căn chỉnh** với phần thân đóng băng trước khi huấn luyện toàn bộ.

Đặc điểm	PhoBERT	ViDeBERTa
Token hóa	BPE	SentencePiece Unigram
Từ vựng	64.000	≈ 128.000
Đầu vào	phải tách từ sẵn	văn bản thô
Điểm log-xác suất	không có	có
Dữ liệu	20GB	$\approx 138\text{GB}$
Điểm neo tiềm năng	hạn chế	phong phú

So sánh theo Nguyen and Nguyen [2020] và Tran et al. [2023]

Lưu ý: SALT gốc dùng chính PhoBERT làm mô hình nguồn; khóa luận chủ đích đổi sang ViDeBERTa.

Ba lý do

- ▶ Xử lý trực tiếp văn bản thô, không phụ thuộc công cụ tách từ bên ngoài.
- ▶ Từ vựng lớn hơn $\Rightarrow$ nhiều ứng viên điểm neo hơn.
- ▶ Học trên dữ liệu tiếng Việt lớn hơn nhiều $\Rightarrow$ không gian véc-tơ mã hóa ngữ nghĩa chính xác hơn.

Giảm kích thước từ vựng

128.000 $\rightarrow$ 30.522 token, giữ token đặc biệt và chọn theo điểm log-xác suất cao nhất – để ViNeoBERT có số tham số ngang NeoBERT gốc.

Điểm neo là gì?

Cặp token *tương ứng ngữ nghĩa* giữa từ vựng tiếng Việt và tiếng Anh – mỗi cặp cho ta một điểm *đã biết* của ánh xạ giữa hai không gian.

Hai vai trò

- ▶ Token neo được khởi tạo bằng cách *sao chép* véc-tơ NeoBERT.
- ▶ Các cặp neo làm *tập giám sát* để học ánh xạ cho những token còn lại.

⇒ Số lượng và chất lượng điểm neo **quyết định** chất lượng khởi tạo.

Nguồn	Ví dụ	Cách xác minh
Trùng mặt chữ	<i>internet</i>	dịch máy trả về chính nó
Chữ số	<i>2024</i>	nhận trực tiếp
Cặp dịch	<i>nước ↔ water</i>	đóng góp của khóa luận

Bẫy: đồng tự khác nghĩa

Việt và Anh cùng dùng chữ Latin, nên trùng chuỗi *chưa chắc* trùng nghĩa: *song* (Việt: song song) $\neq$ *song* (Anh: bài hát). Khóa luận lọc bằng dịch máy [Junczys-Dowmunt et al., 2018] – chỉ giữ khi bản dịch trùng chính chuỗi gốc.

Trước khi khai thác: lọc để chỉ giữ từ tiếng Việt hợp lệ (loại f, j, w, z ; đúng một cụm nguyên âm; tuân thủ quy tắc chính tả $k/gh/ngh, q+u \dots$).

Tầng	Cách khai thác	Ví dụ
1	Dịch ngược phải trùng từ gốc	sách → <i>book</i> → sách
2	Từ ghép, dịch một chiều	bệnh viện → <i>hospital</i>
3	Từ đơn còn lại, lọc thủ công	bổ sung độ phủ

Vì sao dịch ngược lợc đợc từ đa nghĩa

Một từ đa nghĩa thường *không* dịch ngược về chính nó, vì bản dịch trung gian ứng với một nghĩa khác. Ràng buộc dịch ngược trùng khớp do đó tự động giữ lại các cặp tương ứng một–một đáng tin cậy.

Đánh đổi có chủ đích

- ▶ Tầng 1 – ưu tiên *độ chính xác*.
- ▶ Tầng 2 – tăng *số lượng*; từ ghép ít đa nghĩa hơn từ đơn.
- ▶ Tầng 3 – vết nốt *độ phủ*.

Bước 1 – chọn điểm neo gần nghĩa nhất

Do tương đồng trong không gian véc-tơ tĩnh fastText [Bojanowski et al., 2017], rồi lọc bằng *sparsemax* [Martins and Astudillo, 2016]:

$$s_{t,a} = \frac{f_t^\top f_a}{\|f_t\| \|f_a\|}, \quad w_t = \text{sparsemax}(s_t)$$

Khác softmax, *sparsemax* đặt hẳn trọng số của các điểm neo xa nghĩa về 0 – chỉ những điểm thực sự gần mới tham gia.

Bước 2 – học ánh xạ riêng cho token đó

$$X_t = (A_t^{\text{src}})^+ A_t^{\text{tgt}}, \quad e_t = d_t X_t$$

X_t là ánh xạ khớp bình phương tối thiểu, đưa véc-tơ nguồn của các điểm neo về sát véc-tơ đích tương ứng.

Vì sao cục bộ chứ không phải một ánh xạ chung

Hai không gian được huấn luyện độc lập nên *không đẳng cấu* [Ormazabal et al., 2019] và có tính bất đẳng hướng [Ethayarajh, 2019]. Một ánh xạ tuyến tính duy nhất cho cả từ vựng là không đủ; mỗi token được chiếu dựa trên chính các điểm neo lân cận nó.

Các trường hợp còn lại


- ▶ Ít hơn $k_0 = 8$ điểm neo $\Rightarrow$ dùng trung bình có trọng số của các véc-tơ đích.
- ▶ Không có véc-tơ fastText $\Rightarrow$ lấy mẫu ngẫu nhiên khớp thống kê NeoBERT.

Chiều riêng cho cả hai ma trận – khác biệt so với SALT gốc

Vì lớp đầu ra của NeoBERT *không* dùng chung trọng số với lớp véc-tơ đầu vào, hai ma trận có **hình học riêng** và phải được khởi tạo độc lập:

- ▶ **Ma trận véc-tơ E** : véc-tơ đích lấy từ các véc-tơ *đầu vào* NeoBERT của điểm neo.
- ▶ **Ma trận đầu ra W_{dec}** : véc-tơ đích lấy từ các véc-tơ *đầu ra* NeoBERT của cùng tập điểm neo.

Sao chép ma trận véc-tơ sang lớp đầu ra – thói quen kế thừa từ các kiến trúc dùng chung trọng số – gây hại vì hai lớp đảm nhận hai vai trò hình học khác nhau [Gao et al., 2019]. Thực nghiệm ở phần sau xác nhận điều này.



Kết quả sớm

Khởi tạo riêng hai ma trận đạt **67,52** điểm F1, so với **54,09** khi dùng chung trọng số.

1. Hiệu chỉnh độ lớn

$$e_t \leftarrow e_t \cdot \frac{\mu_{\text{neo}}}{\|e_t\|}$$

Đưa mỗi véc-tơ về *độ lớn trung bình* của NeoBERT, giữ nguyên hướng.

Cần thiết vì Pre-RMSNorm nhạy với độ lớn đầu vào.

2. Bias theo tần suất token

$$b_{\text{dec},v} = \log p_v$$

Khởi tạo bias đầu ra bằng log-tần-suất token tiếng Việt [Meister et al., 2023].

Mô hình khởi tốn hàng nghìn bước chỉ để học lại phân phối tần suất.

3. Thu nhỏ trọng số đầu ra

$$y = \gamma W_{\text{dec}} h + b_{\text{dec}}, \quad \gamma = 0,1$$

Để tín hiệu tần suất *chi phối* giai đoạn đầu.

Nhân vô hướng nên vẫn giữ nguyên hướng ngữ nghĩa mà SALT dựng được.

Kết quả của ba bước: điểm xuất phát tốt hơn hẳn


Mất mát khởi điểm xấp xỉ **entropy unigram tiếng Việt** ($\approx 7,3$ nat) thay vì mức đoán ngẫu nhiên $\log |V_t| \approx 10,3$ nat – tức mô hình bắt đầu từ chỗ *đã biết* phân phối từ vựng tiếng Việt.

Giai đoạn 2 – căn chỉnh với thân đóng băng

- ▶ Đóng băng toàn bộ 28 lớp; chỉ huấn luyện hai ma trận mới trên ~ 20 triệu token.
- ▶ Để hai ma trận *khớp với nhau và với phần thân* trước khi cho phần thân thay đổi [de Vries and Nissim, 2021].
- ▶ Chi phí không đáng kể, nhưng giảm $\approx 26\%$ perplexity.

Giai đoạn 3 – tiếp tục tiền huấn luyện

- ▶ Toàn bộ tham số, ~ 5 tỷ token CulturaX tiếng Việt [Nguyen et al., 2024].
- ▶ Khởi động lại tốc độ học khi huấn luyện tiếp [Ibrahim et al., 2024].



Lịch tốc độ học Warmup–Stable–Decay [Hu et al., 2024]

Vì sao chọn WSD thay vì cosine

Lịch cosine buộc phải *cam kết trước* tổng số bước. WSD cho phép rẽ một nhánh làm nguội ngắn tại bất kỳ mốc nào để lấy mô hình hoàn chỉnh, trong khi nhánh chính vẫn tiếp tục – rất hợp với việc đo chất lượng theo từng mốc ngân sách.

1. Giới thiệu

2. Cơ sở lý thuyết

3. Phương pháp đề xuất

4. Thực nghiệm và đánh giá

4.1 Thiết lập

4.2 So sánh khởi tạo

4.3 Kết quả mô hình

5. Kết luận và hướng phát triển

Môi trường

- ▶ GPU NVIDIA A100 80GB (Google Colab).
- ▶ PyTorch + hệ sinh thái Hugging Face.

Dữ liệu

- ▶ Căn chỉnh: ~20 triệu token CulturaX-vi.
- ▶ CPT: ~5 tỷ token (~20GB văn bản), đi qua *đúng một lượt*.
- ▶ Mở rộng ngữ cảnh: ~200 triệu token ở độ dài 4.096.

Mọi kết quả tính chỉnh lấy trung bình 5 seed ngẫu nhiên, báo cáo kèm độ lệch chuẩn.

Mô hình	Tham số	Kiến trúc	Token vi	Ngữ cảnh
PhoBERT-base	135M	RoBERTa	~140 tỷ	512
PhoBERT-base-v2	135M	RoBERTa	>140 tỷ	512
PhoBERT-large	370M	RoBERTa	~140 tỷ	512
XLM-R-base	278M	RoBERTa	hàng trăm tỷ	512
XLM-R-large	560M	RoBERTa	hàng trăm tỷ	512
ViNeoBERT	≈250M	NeoBERT	5 tỷ	4.096

Các mô hình so sánh [Nguyen and Nguyen, 2020; Conneau et al., 2020]

Điểm cần chú ý khi đọc mọi kết quả sau

ViNeoBERT chỉ tiếp xúc **3,5%** lượng token tiếng Việt mà PhoBERT-large đã huấn luyện.

Nhóm năng lực	Bộ dữ liệu	Độ đo
Hỏi đáp đọc hiểu	UIT-ViQuAD 2.0	EM, F1
Suy luận	XNLI, ViANLI, QNLI	Acc, F1-macro
Phân loại văn bản	UIT-VSFC, VSMEC, ViCTSD	F1
Chấp nhận ngữ pháp	ViCoLA-syn	MCC
Gán nhãn từ loại	UD-VTB	F1-macro
Tương đồng ngữ nghĩa	STS, Paraphrase	Spearman, F1
Biểu diễn câu	Retrieval, Reranking	nDCG@10, MRR

Hai câu hỏi nghiên cứu

Câu hỏi 1

Phương án *khởi tạo* nào tốt nhất?

→ so sánh có kiểm soát, cùng ngân sách token.


Câu hỏi 2

Mô hình cuối đạt chất lượng ra sao so với các mô hình hiện có?

→ đường cong theo ngân sách + bảng 12 tác vụ.

UIT-ViQuAD được chọn làm thước đo quyết định vì nó buộc mô hình dùng đến ngữ nghĩa thực sự của từng token.

SALT có thực sự đưa từ vựng tiếng Việt vào đúng không gian?



Hình: lớp véc-tơ tiếng Việt trước và sau SALT, chiếu bằng PCA trên cùng một hệ trục


Cách đọc hình

- ▶ Vàng: véc-tơ tiếng Việt (ViDeBERTa). Xanh: véc-tơ NeoBERT gốc.
- ▶ Token điểm neo *đã bị loại khỏi hình* – chúng vốn được sao chép nguyên vẹn nên sẽ tạo vùng chồng lấp giả tạo.

Kết quả

- ▶ Khoảng cách hai tâm giảm từ **0,8** còn **0,3**; độ trải cũng thu về khớp với NeoBERT.
- ⇒ Phép chiếu đưa từ vựng tiếng Việt về đúng vùng mà phần thân được huấn luyện để xử lý.

Hệ số tỉ lệ trọng số đầu ra γ là bắt buộc





Hình: mất mát MLM theo hệ số tỉ lệ γ

Ba phương án *giống hệt nhau* về khởi tạo, chỉ khác đúng γ .

γ	Mất mát đầu	Chuẩn grad
1,0	10,18	68,4
0,5	8,13	15,8
0,1	7,21	2,1

- ▶ γ lớn: logit *nhiều* từ ma trận vừa chiếu lẫn át tín hiệu tần suất; cập nhật đầu tiên biên độ rất lớn nhưng ít thông tin $\Rightarrow$ **mắc kẹt** quanh 6,6–6,8.
- ▶ $\gamma = 0,1$: khởi đầu ngay tại entropy unigram rồi hội tụ về **3,14**.



(a) mất mát MLM trên tập đánh giá (b) F1 trên UIT-ViQuAD tại mốc 100 triệu token, thanh lỗi qua 3 seed


Giá trị của hướng ngữ nghĩa

Đường cơ sở *khớp mô-men* đã có đúng độ lớn, ánh xạ đầu ra và hệ số tần suất – chỉ thiếu *hướng véc-tơ*. Khoảng cách **+11,2 điểm** vì thế quy hết về phần lỗi của phương pháp.

Dùng chung trọng số gây hại

54,09 so với 56,27 – hai lớp có vai trò hình học khác nhau. Căn chỉnh với thân đóng băng nâng tiếp lên **72,15**, độ lệch chuẩn giảm hơn một bậc (1,61 → 0,12).

Quá trình huấn luyện: khởi đầu thấp, hội tụ nhanh




Hình: đường cong mất mát giai đoạn CPT theo lịch WSD

- ▶ Nhờ khởi tạo SALT, mất mát bắt đầu ở $\approx 6,5$ – đã nằm *dưới* mức đoán ngẫu nhiên ($\approx 10,3$) và gần entropy unigram tiếng Việt ($\approx 7,3$).
- ▶ Chỉ trong **0,2 tỷ token** đầu, mất mát đã rơi xuống dưới 2,0.
- ▶ Pha làm nguội cuối kéo mất mát về $\approx 1,1$; perplexity trên tập đánh giá giảm còn **3,2**.

⇒ Phần thân kế thừa từ NeoBERT *không phải* học lại tiếng Việt từ đầu.

Phần lớn chất lượng đến từ những trăm triệu token đầu tiên



Hình: F1 trên UIT-ViQuAD theo số token CPT (thang log)

Mốc ngân sách

F1

0,1 tỷ token (2% ngân sách) 72,15

0,5 tỷ token 74,79

5 tỷ token (cuối) **76,62**

XLM-R-base (cuối) 73,32

PhoBERT-base-v2 77,4

PhoBERT-large 78,0

- ▶ Vượt XLM-R-base ngay tại mốc **0,5 tỷ token**.
- ▶ Còn cách PhoBERT-base-v2 **0,8 điểm** và PhoBERT-large **1,4 điểm** – xu hướng vẫn đang đi lên.

Kết quả trên 12 tác vụ hiểu tiếng Việt

Tác vụ	Độ đo	PhoBERT-v2	PhoBERT-L	XLM-R-B	XLM-R-L	ViNeoBERT
UIT-VSFC	F1-w	0,9345	0,9356	0,9281	0,9312	0,9284
UIT-VSMEC	F1-m	0,6415	0,6132	0,6145	0,3125	0,6163
UIT-ViCTSD	F1-m	0,7455	0,7526	0,7110	0,5759	0,7315
ViCoLA-syn	MCC	0,8103	0,7915	0,7827	0,4845	0,7789
XNLI (vi)	Acc	0,7720	0,7769	0,7541	0,8000	0,7714
ViANLI	F1-m	0,4529	0,3882	0,3625	0,1666	0,4273
QNLI (vi)	Acc	0,8872	0,8861	0,8592	0,8940	0,8791
UD-VTB (POS)	F1-m	0,7799	0,7879	0,7827	0,8062	0,8089
STS (vi)	Spearman	0,8557	0,8509	0,8226	0,8644	0,8392
Paraphrase	F1-m	0,9351	0,9400	0,9016	0,9437	0,9276
Retrieval	nDCG@10	0,4719	0,4659	0,1386	0,2565	0,4061
Reranking	MRR	0,8922	0,8794	0,5282	0,6741	0,8448

- ▶ Cao hơn XLM-R-base **11/12** tác vụ (12/13 nếu tính đọc hiểu).
- ▶ **Dẫn đầu cả bảng** ở gán nhãn từ loại.

- ▶ XLM-R-large *bất ổn* rõ rệt trên dữ liệu nhỏ (VSMEC 0,31; ViANLI 0,17); ViNeoBERT ổn định trên cả 12 tác vụ.
- ▶ Điểm mạnh tập trung ở biểu diễn *cấp token* – đúng năng lực kế thừa từ phần thân 28 lớp.

Mô hình	Token tiếng Việt	F1 ViQuAD
PhoBERT-large	~140 tỷ (40 lượt)	78,0
PhoBERT-base-v2	>140 tỷ	77,4
XLM-R-base	hàng trăm tỷ	73,3
ViNeoBERT	5 tỷ (1 lượt)	76,6

PhoBERT-large: ~140 tỷ token


ViNeoBERT: 5 tỷ (3,5%)

Con số đáng nói nhất

Với **3,5%** lượng token mà PhoBERT-large đã huấn luyện, ViNeoBERT đạt **98,3%** điểm F1 của mô hình đó – dù PhoBERT-large lớn gấp 1,5 lần về tham số.

- ▶ Xác nhận trực tiếp giả thuyết của khóa luận: *tái sử dụng* không gian biểu diễn cho phép kế thừa năng lực phần thân thay vì học lại từ đầu.
- ▶ Có ý nghĩa đặc biệt với các ngôn ngữ ít tài nguyên.

Biến trên 4.096 token thành năng lực dùng được



Hình: pseudo-perplexity theo độ dài chuỗi, trước và sau pha mở rộng ngữ cảnh

Toàn bộ CPT chạy ở độ dài 1.024 token. Sau đó huấn luyện thêm **~200 triệu token** (**~4%** ngân sách) ở độ dài 4.096.

- ▶ **Trước:** nhờ tính tương đối của RoPE, mô hình ngoại suy ổn định tới $\approx 2.500\text{--}3.000$ token, sau đó chất lượng *giảm nhanh* (nhiều điểm vượt 10).
- ▶ **Sau:** pseudo-perplexity phẳng quanh **2–3** trên toàn dải tới 4.096 token.

Đo theo đúng giao thức của NeoBERT [Salazar et al., 2020].

1. Giới thiệu
2. Cơ sở lý thuyết
3. Phương pháp đề xuất
4. Thực nghiệm và đánh giá
5. Kết luận và hướng phát triển

Đóng góp của khóa luận

- ▶ **ViNeoBERT** – Encoder hiện đại ≈ 250 triệu tham số cho tiếng Việt, kế thừa RoPE/SwiGLU/Pre-RMSNorm và trần ngữ cảnh 4.096 token.
- ▶ **Quy trình chuyển đổi ngôn ngữ** ba giai đoạn, lần đầu áp dụng cho một kiến trúc Encoder thể hệ mới.
- ▶ **Ba cải tiến so với SALT gốc**: điểm neo theo cặp dịch, khởi tạo riêng lớp đầu ra, giai đoạn căn chỉnh với thân đóng băng.
- ▶ **Bộ mã nguồn công khai** cùng toàn bộ kịch bản huấn luyện.

Kết quả chính

- ▶ **76,62** điểm F1 trên UIT-ViQuAD – hơn XLM-R-base 3,3 điểm.
 - ▶ Cao hơn XLM-R-base ở **11/12** tác vụ; dẫn đầu cả bảng ở gán nhãn từ loại.
 - ▶ Từng lựa chọn thiết kế đều được kiểm chứng có kiểm soát: $\gamma = 0,1$, khởi tạo riêng hai ma trận (67,52 so với 54,09), căn chỉnh với thân đóng băng (-26% perplexity).
 - ▶ Ngữ cảnh 4.096 token trở thành năng lực dùng được với chỉ ~ 200 triệu token bổ sung.
- ⇒ Tất cả đạt được với **3,5%** lượng token của PhoBERT-large.

Hạn chế

- ▶ **Ngân sách huấn luyện:** 5 tỷ token vẫn nhỏ; chưa vượt PhoBERT-base-v2 ở nhóm phân loại câu ngắn.
- ▶ **Phạm vi đánh giá:** chưa khảo sát nhận dạng thực thể có tên; Retrieval–Reranking mới chạy một lần nên chưa ước lượng phương sai.
- ▶ **Ngữ cảnh dài:** mới kiểm chứng bằng độ đo nội tại (pseudo-perplexity), chưa có tác vụ ứng dụng.
- ▶ **Tokenizer:** ảnh hưởng của việc không tách từ chưa được phân tích riêng.

Hướng phát triển

1. **Mở rộng ngân sách CPT** – đường cong F1 vẫn đang đi lên.
2. **Trộn lại 5–10% dữ liệu tiếng Anh** như cơ chế phát lại (replay) để giảm mất thông tin [Elhady et al., 2025].
3. **Đánh giá trên tác vụ ngữ cảnh dài** (hỏi đáp đa đoạn, truy xuất tài liệu); vượt trần 4.096 token bằng YaRN [Peng et al., 2023].
4. **Mở rộng bộ đánh giá** – NER, truy xuất quy mô lớn, lặp lại nhóm biểu diễn câu qua nhiều seed.
5. **Tổng quát hóa quy trình** sang ngôn ngữ ít tài nguyên khác và kiến trúc nền khác.

**Xin chân thành cảm ơn quý thầy cô
đã lắng nghe phần trình bày.**

Nhóm rất mong nhận được các ý kiến đóng góp của hội đồng.

- Bojanowski, P., Grave, E., Joulin, A., and Mikolov, T. (2017). Enriching word vectors with subword information. *Transactions of the Association for Computational Linguistics*, 5:135–146.
- Conneau, A., Khandelwal, K., Goyal, N., et al. (2020). Unsupervised cross-lingual representation learning at scale. In *Proceedings of ACL*, pages 8440–8451.
- de Vries, W. and Nissim, M. (2021). As good as new. how to successfully recycle English GPT-2 to make models for other languages. In *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*.
- Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*, pages 4171–4186.
- Dobler, K. and de Melo, G. (2023). FOCUS: Effective embedding initialization for monolingual specialization of multilingual models. In *Proceedings of EMNLP*.
- Elhady, A., Agirre, E., and Artetxe, M. (2025). Emergent abilities of large language models under continued pretraining for language adaptation. In *Proceedings of ACL*.
- Ethayarajh, K. (2019). How contextual are contextualized word representations? comparing the geometry of BERT, ELMo, and GPT-2 embeddings. In *Proceedings of EMNLP-IJCNLP*.
- Gao, J., He, D., Tan, X., Qin, T., Wang, L., and Liu, T.-Y. (2019). Representation degeneration problem in training natural language generation models. In *International Conference on Learning Representations (ICLR)*.
- Hu, S., Tu, Y., Han, X., He, C., Cui, G., Long, X., et al. (2024). MiniCPM: Unveiling the potential of small language models with scalable training strategies. *arXiv preprint arXiv:2404.06395*.
- Ibrahim, A., Thérien, B., Gupta, K., et al. (2024). Simple and scalable strategies to continually pre-train large language models. *Transactions on Machine Learning Research (TMLR)*.

- Junczys-Dowmunt, M., Grundkiewicz, R., Dwojak, T., et al. (2018). Marian: Fast neural machine translation in C++. In *Proceedings of ACL 2018, System Demonstrations*.
- Le Breton, L., Fournier, Q., El Mezouar, M., Morris, J. X., and Chandar, S. (2025). NeoBERT: A next-generation BERT. *arXiv preprint arXiv:2502.19587*.
- Lee, S., Hong, S., Moon, H., and Lim, H. (2025). Semantic aware linear transfer by recycling pre-trained language models for cross-lingual transfer. In *Findings of the Association for Computational Linguistics: ACL 2025*.
- Levine, Y., Wies, N., Sharir, O., Bata, H., and Shashua, A. (2020). The depth-to-width interplay in self-attention. In *Advances in Neural Information Processing Systems (NeurIPS)*.
- Liu, Y., Lin, P., Wang, M., and Schütze, H. (2024). OFA: A framework of initializing unseen subword embeddings for efficient large-scale multilingual continued pretraining. In *Findings of the Association for Computational Linguistics: NAACL 2024*.
- Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., and Stoyanov, V. (2019). RoBERTa: A robustly optimized BERT pretraining approach. *arXiv preprint arXiv:1907.11692*.
- Martins, A. F. T. and Astudillo, R. F. (2016). From softmax to sparsemax: A sparse model of attention and multi-label classification. In *Proceedings of the 33rd International Conference on Machine Learning (ICML)*.
- Meister, C., Stokowiec, W., Pimentel, T., Yu, L., Rimell, L., and Kuncoro, A. (2023). A natural bias for language generation models. In *Proceedings of ACL*.
- Minixhofer, B., Paischer, F., and Rekabsaz, N. (2022). WECHSEL: Effective initialization of subword embeddings for cross-lingual transfer of monolingual language models. In *Proceedings of NAACL-HLT*, pages 3992–4006.
- Nguyen, D. Q. and Nguyen, A. T. (2020). PhoBERT: Pre-trained language models for Vietnamese. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 1037–1042.

- Nguyen, T., Nguyen, C. V., Lai, V. D., et al. (2024). CulturaX: A cleaned, enormous, and multilingual dataset for large language models in 167 languages. In *Proceedings of LREC-COLING*, pages 4226–4237.
- Ormazabal, A., Artetxe, M., Labaka, G., Soroa, A., and Agirre, E. (2019). Analyzing the limitations of cross-lingual word embedding mappings. In *Proceedings of ACL*, pages 4990–4995.
- Peng, B., Quesnelle, J., Fan, H., and Shippole, E. (2023). YaRN: Efficient context window extension of large language models. In *arXiv preprint arXiv:2309.00071*.
- Salazar, J., Liang, D., Nguyen, T. Q., and Kirchhoff, K. (2020). Masked language model scoring. In *Proceedings of ACL*, pages 2699–2712.
- Shazeer, N. (2020). GLU variants improve transformer. *arXiv preprint arXiv:2002.05202*.
- Su, J., Lu, Y., Pan, S., Murtadha, A., Wen, B., and Liu, Y. (2024). RoFormer: Enhanced transformer with rotary position embedding. *Neurocomputing*, 568.
- Tran, C. D., Pham, N. H., Nguyen, A., Hy, T. S., and Vu, T. (2023). ViDeBERTa: A powerful pre-trained language model for Vietnamese. In *Findings of the Association for Computational Linguistics: EACL 2023*, pages 1071–1078.
- Zhang, B. and Sennrich, R. (2019). Root mean square layer normalization. In *Advances in Neural Information Processing Systems (NeurIPS)*.