

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN, ĐHQG-HCM
KHOA CÔNG NGHỆ THÔNG TIN



KHÓA LUẬN TỐT NGHIỆP

NGHIÊN CỨU PHƯƠNG PHÁP XÂY DỰNG NEOBERT CHO TIẾNG VIỆT

Giảng viên hướng dẫn

TS. Nguyễn Hồng Bửu Long
TS. Lương An Vinh

Giảng viên phản biện

ThS. Trần Thị Thảo Nhi

Sinh viên thực hiện

Bùi Khắc Trung – 22120396
Trần Anh Tú – 22120400

Tp. Hồ Chí Minh, tháng 07 năm 2026

1. Giới thiệu
2. Cơ sở lý thuyết
3. Phương pháp đề xuất
 - 3.1 Tổng quan
 - 3.2 Tập điểm neo
 - 3.3 Khởi tạo SALT
 - 3.4 Huấn luyện
4. Thực nghiệm và đánh giá
 - 4.1 Thiết lập
 - 4.2 So sánh khởi tạo
 - 4.3 Kết quả mô hình
5. Kết luận và hướng phát triển

Câu hỏi của khóa luận


Làm sao chuyển một mô hình
Encoder thể hệ mới sang tiếng Việt
mà không huấn luyện lại từ đầu?

Encoder-only là gì?

- ▶ Đọc câu theo *cả hai chiều*, sinh ra biểu diễn ngữ nghĩa cho từng từ – không sinh văn bản.
- ▶ Là lựa chọn mặc định cho phân loại văn bản, gán nhãn, hỏi đáp trích xuất, tìm kiếm ngữ nghĩa.
- ▶ BERT và RoBERTa vẫn đang được dùng rộng rãi trong thực tế.

Vấn đề

Trong khi các mô hình sinh văn bản (LLM) tiến hóa liên tục, các mô hình dòng Encoder-only đã *chững lại nhiều năm*, chỉ được cập nhật tiếp từ cuối năm 2024.



NeoBERT đưa các cải tiến của thể hệ LLM trở lại kiến trúc Encoder:

- ▶ **RoPE** – mã hóa vị trí bằng phép quay
- ▶ **SwiGLU** – mạng truyền thẳng có cổng
- ▶ **Pre-RMSNorm** – chuẩn hóa trước mỗi lớp con
- ▶ **Sâu mà hẹp** – 28 lớp, kích thước ẩn 768

Chỉ **250 triệu tham số** nhưng vượt BERT_{large} và RoBERTa_{large} trên chuẩn đánh giá MTEB, đồng thời hỗ trợ ngữ cảnh **4.096 token** – gấp 8 lần BERT.

Cấu hình NeoBERT

Số lớp / kích thước ẩn	28 / 768
Tham số	≈ 250 triệu
Mã hóa vị trí	RoPE
Kích hoạt FFN	SwiGLU
Chuẩn hóa	Pre-RMSNorm
Ngữ cảnh tối đa	4.096 token
Dữ liệu tiền huấn luyện	2,1 nghìn tỷ token
Ngôn ngữ	chỉ tiếng Anh

Bảng cấu hình theo Le Breton et al. [2025]

Ba trở ngại

1. Encoder tiếng Việt hiện có (PhoBERT [Nguyen and Nguyen, 2020], ViDeBERTa [Tran et al., 2023]) dùng kiến trúc cũ, giới hạn 512 token.
2. NeoBERT gốc được huấn luyện trên **2,1 nghìn tỷ token**; huấn luyện lại từ đầu ở quy mô tương đương vượt quá nguồn lực của nhóm.
3. Thay lớp véc-tơ rồi huấn luyện tiếp một cách ngây thơ dễ gây **mất thông tin** (*catastrophic forgetting*).

Ý tưởng của khóa luận


Tái sử dụng thay vì huấn luyện lại

Giữ nguyên *phần thân* NeoBERT đã học từ tiếng Anh; chỉ thay lớp từ vựng, và khởi tạo lớp mới bằng cách *mượn* không gian ngữ nghĩa tiếng Việt sẵn có của ViDeBERTa.


Mục tiêu cụ thể

- ▶ Xây dựng **ViNeoBERT** bằng kỹ thuật SALT [Lee et al., 2025] có cải tiến.
- ▶ Chứng minh bằng thực nghiệm rằng cách này *tiết kiệm hơn nhiều* so với huấn luyện lại.

1. Giới thiệu
2. Cơ sở lý thuyết
3. Phương pháp đề xuất
4. Thực nghiệm và đánh giá
5. Kết luận và hướng phát triển




RoPE: mã hóa vị trí bằng phép quay véc-tơ




Nguồn: Su et al. [2024]

Post-LN (BERT)



chuẩn hóa nằm trên residual

Pre-RMSNorm



residual thông suốt từ đầu đến cuối

1. Đặt trước $\Rightarrow$ gradient không phình ở lớp cuối

Chuẩn gradient tại lớp cuối $\|\partial\mathcal{L}/\partial W^{L,2}\|_F$ khi khởi tạo (L lớp, d chiều):

$$\underbrace{\mathcal{O}(d\sqrt{\ln d})}_{\text{Post-LN}}$$

so với

$$\underbrace{\mathcal{O}(d\sqrt{\ln d / L})}_{\text{Pre-LN}}$$

Post-LN chuẩn hóa lại residual ở *mọi* lớp: gradient **không nhỏ đi** khi mạng sâu thêm, buộc phải dùng *warm-up* tốc độ học. Pre-LN chia thêm $\sqrt{L}$ nên **28 lớp** của NeoBERT huấn luyện ổn định [Xiong et al., 2020]

2. Bỏ trung bình $\Rightarrow$ mỗi lớp rẻ hơn

$$\underbrace{\frac{a_i - \mu}{\sigma} g_i + b_i}_{\text{LayerNorm}} \longrightarrow \underbrace{\frac{a_i}{\text{RMS}(a)}}_{\text{RMSNorm}} g_i, \text{RMS}(a) = \sqrt{\frac{1}{n} \sum_i a_i^2}$$

[Zhang and Sennrich, 2019]

1. RoPE – thuận lợi

- ▶ Vị trí được áp *bên trong* mỗi lớp, **không nằm** trong ma trận véc-tơ.
- ⇒ Thay toàn bộ lớp từ vựng tiếng Việt *không đụng chạm* cơ chế vị trí.


2. Pre-RMSNorm – ràng buộc

- ▶ Chuẩn hóa chia theo *độ lớn* véc-tơ; lớp véc-tơ đi thẳng vào luồng chính qua residual.
- ⇒ Nếu độ lớn véc-tơ mới lệch khỏi thống kê NeoBERT, sai lệch bị khuếch đại qua 28 lớp.

3. Lớp đầu ra không dùng chung trọng số


Khác BERT/RoBERTa, đầu MLM của NeoBERT là một ma trận *độc lập* với ma trận véc-tơ đầu vào. Vì vậy chuyển sang tiếng Việt phải khởi tạo **cả hai ma trận**, mỗi ma trận trong đúng không gian của nó.

Đổi ngôn ngữ: khởi tạo lớp véc-tơ thế nào?



Khởi tạo ngẫu nhiên buộc phần thân học lại từ tín hiệu vô nghĩa [de Vries and Nissim, 2021]. Các phương pháp theo ngữ nghĩa dùng véc-tơ tĩnh để bắc cầu; **SALT** đi xa hơn – lấy thẳng không gian véc-tơ của một mô hình **đã tiền huấn luyện** ở ngôn ngữ đích.

SALT: tái sử dụng không gian véc-tơ của mô hình ngôn ngữ đích



Nguồn: Lee et al. [2025]

1. Giới thiệu

2. Cơ sở lý thuyết

3. Phương pháp đề xuất

3.1 Tổng quan


3.2 Tập điểm neo

3.3 Khởi tạo SALT

3.4 Huấn luyện

4. Thực nghiệm và đánh giá

5. Kết luận và hướng phát triển



Ba cải tiến của khóa luận so với SALT gốc

1. Mở rộng tập điểm neo bằng các cặp dịch Anh–Việt.
2. Khởi tạo riêng lớp đầu ra, kèm hệ số điều chỉnh theo tần suất token và thu nhỏ trọng số đầu ra.
3. Bổ sung giai đoạn căn chỉnh với phần thân đóng băng trước khi huấn luyện toàn bộ.

Đặc điểm	PhoBERT	ViDeBERTa
Token hóa	BPE	SentencePiece Unigram
Từ vựng	64.000	≈ 128.000
Đầu vào	phải tách từ sẵn	văn bản thô
Điểm log-xác suất	không có	có
Dữ liệu	20GB	$\approx 138\text{GB}$
Điểm neo tiềm năng	hạn chế	phong phú

So sánh theo Nguyen and Nguyen [2020] và Tran et al. [2023]

Ba lý do

- ▶ Xử lý trực tiếp văn bản thô, không phụ thuộc công cụ tách từ bên ngoài.
- ▶ Từ vựng lớn hơn $\Rightarrow$ nhiều ứng viên điểm neo hơn.
- ▶ Học trên dữ liệu tiếng Việt lớn hơn nhiều $\Rightarrow$ không gian véc-tơ mã hóa ngữ nghĩa chính xác hơn.

Giảm kích thước từ vựng

128.000 $\rightarrow$ 30.522 token, giữ token đặc biệt và chọn theo điểm log-xác suất cao nhất – để ViNeoBERT có số tham số ngang NeoBERT gốc.

Điểm neo là gì?

Cặp token *đồng nghĩa* giữa hai từ vựng – một điểm *đã biết* của ánh xạ.

Hai vai trò

- ▶ **Token neo:** khởi tạo bằng cách sao chép véc-tơ NeoBERT tương ứng.
- ▶ **Các cặp neo:** làm *dữ liệu mẫu* để học phép ánh xạ – dùng cho các token *không phải điểm neo*.


⇒ Số lượng điểm neo **quyết định** chất lượng khởi tạo.

SALT gốc chỉ lấy điểm neo *trùng mặt chữ* nên rất ít cho cặp Anh–Việt – khóa luận mở rộng bằng **cặp dịch**.

Nguồn	Ví dụ	Cách xác minh
Trùng mặt chữ	<i>internet</i>	dịch máy trả về chính nó
Chữ số	<i>2024</i>	nhận trực tiếp
Cặp dịch	<i>nước ↔ water</i>	đóng góp của khóa luận

Bẫy: đồng tự khác nghĩa

Việt và Anh cùng dùng chữ Latin, nên trùng chuỗi *chưa chắc* trùng nghĩa: *song* (Việt: song song) $\neq$ *song* (Anh: bài hát). Khóa luận lọc bằng dịch máy [Junczys-Dowmunt et al., 2018] – chỉ giữ khi bản dịch trùng chính chuỗi gốc.



Vì sao ràng buộc dịch ngược lọc được từ đa nghĩa

Một từ đa nghĩa thường *không* dịch ngược về chính nó, vì bản dịch trung gian ứng với một nghĩa khác $\Rightarrow$ ràng buộc này tự động giữ lại các cặp tương ứng **một–một** đáng tin cậy.

Bước 1 – chọn điểm neo gần nghĩa nhất

Do tương đồng trong không gian véc-tơ tĩnh fastText [Bojanowski et al., 2017], rồi lọc bằng *sparsemax* [Martins and Astudillo, 2016]:

$$s_{t,a} = \frac{f_t^\top f_a}{\|f_t\| \|f_a\|}, \quad w_t = \text{sparsemax}(s_t)$$

Khác softmax, *sparsemax* đặt hẳn trọng số của các điểm neo xa nghĩa về 0 – chỉ những điểm thực sự gần mới tham gia.

Bước 2 – học ánh xạ riêng cho token đó

$$X_t = (A_t^{\text{src}})^+ A_t^{\text{tgt}}, \quad e_t = d_t X_t$$

X_t là ánh xạ khớp bình phương tối thiểu, đưa véc-tơ nguồn của các điểm neo về sát véc-tơ đích tương ứng.

Vì sao cục bộ chứ không phải một ánh xạ chung

Hai không gian được huấn luyện độc lập nên *không đẳng cấu* [Ormazabal et al., 2019] và có tính bất đẳng hướng [Ethayarajh, 2019]. Một ánh xạ tuyến tính duy nhất là không đủ; mỗi token được chiếu dựa trên chính các điểm neo lân cận nó.

Các trường hợp còn lại


- ▶ Ít hơn $k_0 = 8$ điểm neo $\Rightarrow$ dùng trung bình có trọng số của các véc-tơ đích.
- ▶ Không có véc-tơ fastText $\Rightarrow$ lấy mẫu ngẫu nhiên khớp thống kê NeoBERT.

Chiều riêng cho cả hai ma trận – khác biệt so với SALT gốc

Vì lớp đầu ra của NeoBERT *không* dùng chung trọng số với lớp véc-tơ đầu vào, hai ma trận có **hình học riêng** và phải được khởi tạo độc lập:


- ▶ **Ma trận véc-tơ E** : véc-tơ đích lấy từ các véc-tơ *đầu vào* NeoBERT của điểm neo.
- ▶ **Ma trận đầu ra W_{dec}** : véc-tơ đích lấy từ các véc-tơ *đầu ra* NeoBERT của cùng tập điểm neo.

Sao chép ma trận véc-tơ sang lớp đầu ra – thói quen kế thừa từ các kiến trúc dùng chung trọng số – gây hại vì hai lớp đảm nhận hai vai trò hình học khác nhau [Gao et al., 2019]. Thực nghiệm ở phần sau xác nhận điều này.



Kết quả

Khởi tạo riêng hai ma trận đạt **67,52** điểm F1, so với **54,09** khi dùng chung trọng số.



Kết quả của ba bước: điểm xuất phát tốt hơn hẳn


Mất mát khởi điểm xấp xỉ **entropy unigram tiếng Việt** ($\approx 7,3 \text{ nat}$) thay vì mức đoán ngẫu nhiên $\log |V_t| \approx 10,3 \text{ nat}$ – tức mô hình bắt đầu từ chỗ *đã biết* phân phối từ vựng tiếng Việt.

Giai đoạn 2 – căn chỉnh với thân đóng băng

- ▶ Đóng băng toàn bộ 28 lớp; chỉ huấn luyện hai ma trận mới trên ~ 20 triệu token.
- ▶ Để hai ma trận *khớp với nhau và với phần thân* trước khi cho phần thân thay đổi [de Vries and Nissim, 2021].
- ▶ Chi phí không đáng kể, nhưng giảm $\approx 26\%$ perplexity.

Giai đoạn 3 – tiếp tục tiền huấn luyện

- ▶ Toàn bộ tham số, ~ 5 tỷ token CulturaX tiếng Việt [Nguyen et al., 2024].
- ▶ Khởi động lại tốc độ học khi huấn luyện tiếp [Ibrahim et al., 2024].



Lịch tốc độ học Warmup–Stable–Decay [Hu et al., 2024]

Vì sao chọn WSD thay vì cosine

Lịch cosine buộc phải *cam kết trước* tổng số bước. WSD cho phép rẽ một nhánh làm nguội ngắn tại bất kỳ mốc nào để lấy mô hình hoàn chỉnh, trong khi nhánh chính vẫn tiếp tục – rất hợp với việc đo chất lượng theo từng mốc ngân sách.

1. Giới thiệu

2. Cơ sở lý thuyết

3. Phương pháp đề xuất

4. Thực nghiệm và đánh giá

4.1 Thiết lập

4.2 So sánh khởi tạo

4.3 Kết quả mô hình

5. Kết luận và hướng phát triển

Môi trường

- ▶ GPU NVIDIA A100 80GB (Google Colab).
- ▶ PyTorch + hệ sinh thái Hugging Face.

Dữ liệu

- ▶ Căn chỉnh: ~20 triệu token CulturaX-vi.
- ▶ CPT: ~5 tỷ token (~20GB văn bản), đi qua *đúng một lượt*.
- ▶ Mở rộng ngữ cảnh: ~200 triệu token ở độ dài 4.096.

Mô hình	Tham số	Kiến trúc	Token vi	Ngữ cảnh
PhoBERT-base	135M	RoBERTa	~140 tỷ	512
PhoBERT-base-v2	135M	RoBERTa	>140 tỷ	512
PhoBERT-large	370M	RoBERTa	~140 tỷ	512
XLM-R-base	278M	RoBERTa	hàng trăm tỷ	512
XLM-R-large	560M	RoBERTa	hàng trăm tỷ	512
ViNeoBERT	≈250M	NeoBERT	5 tỷ	4.096

Điểm cần chú ý khi đọc mọi kết quả sau

ViNeoBERT chỉ tiếp xúc **3,5%** lượng token tiếng Việt mà PhoBERT-large đã huấn luyện.

Nhóm năng lực	Bộ dữ liệu	Độ đo
Hỏi đáp đọc hiểu	UIT-ViQuAD 2.0	EM, F1
Suy luận	XNLI, ViANLI, QNLI	Acc, F1-macro
Phân loại văn bản	UIT-VSFC, VSMEC, ViCTSD	F1
Chấp nhận ngữ pháp	ViCoLA-syn	MCC
Gán nhãn từ loại	UD-VTB	F1-macro
Tương đồng ngữ nghĩa	STS, Paraphrase	Spearman, F1
Biểu diễn câu	Retrieval, Reranking	nDCG@10, MRR

Câu hỏi 1

Phương án *khởi tạo* nào tốt nhất?


→ so sánh có kiểm soát, cùng ngân sách token.

Câu hỏi 2

Mô hình cuối đạt chất lượng ra sao so với các mô hình hiện có?

→ đường cong theo ngân sách + bảng 13 tác vụ.

SALT có thực sự đưa từ vựng tiếng Việt vào đúng không gian?




Hình: lớp véc-tơ tiếng Việt trước và sau SALT, chiếu PCA trên cùng một hệ trục

Vàng: véc-tơ ViDeBERTa · Xanh: NeoBERT gốc.
Khoảng cách hai tâm: **0,8** → **0,3**.

⇒ Phép chiếu đưa từ vựng tiếng Việt về đúng vùng mà phần thân được huấn luyện để xử lý.

Thu nhỏ trọng số lớp đầu ra là bắt buộc





Hình: mất mát MLM theo mức thu nhỏ γ

Trọng số lớp đầu ra được nhân với một hệ số $\gamma < 1$ để *thu nhỏ* lại. Ba phương án *giống hệt nhau* về khởi tạo, chỉ khác mức thu nhỏ.

Mức thu nhỏ	Mất mát đầu	Chuẩn grad
1,0	10,18	68,4
0,5	8,13	15,8
0,1	7,21	2,1


- ▶ **Thu nhỏ ít** (γ lớn): logit *nhiều* từ ma trận vừa chiếu lần át tín hiệu tần suất; cập nhật đầu tiên biên độ rất lớn nhưng ít thông tin $\Rightarrow$ **mắc kẹt** quanh 6,6–6,8.
- ▶ **Thu nhỏ mạnh** ($\gamma = 0,1$): khởi đầu ngay tại entropy unigram rồi hội tụ về **3,14**.

So sánh năm phương án khởi tạo ở cùng ngân sách



(a) mất mát MLM trên tập đánh giá (b) F1 trên UIT-ViQuAD tại mốc 100 triệu token, thanh lỗi qua 3 seed

Quá trình huấn luyện: khởi đầu thấp, hội tụ nhanh




Hình: đường cong mất mát giai đoạn CPT theo lịch WSD

- ▶ Bắt đầu ở $\approx 6,5$ – dưới mức đoán ngẫu nhiên ($\approx 10,3$).
- ▶ Dưới 2,0 chỉ sau **0,2 tỷ token**.
- ▶ Pha làm nguội kéo mất mát huấn luyện về $\approx 1,1$.
- ▶ Perplexity trên tập đánh giá: **3,2**.

⇒ Phần thân *không phải* học lại tiếng Việt từ đầu.

Khởi tạo SALT cho điểm xuất phát cao: 72,15 F1 ở 2% ngân sách



Hình: F1 trên UIT-ViQuAD theo số token CPT (thang log)

Mốc ngân sách

F1

0,1 tỷ token (2% ngân sách) 72,15

0,5 tỷ token 74,79

5 tỷ token (cuối) **76,62**

XLM-R-base (cuối) 73,32

PhoBERT-base-v2 77,4

PhoBERT-large 78,0

- ▶ Vượt XLM-R-base ngay tại mốc **0,5 tỷ token**.
- ▶ Còn cách PhoBERT-base-v2 **0,8 điểm** và PhoBERT-large **1,4 điểm** – xu hướng vẫn đang đi lên.

Kết quả 13 tác vụ: bám sát PhoBERT-large với 3,5% dữ liệu

Tác vụ	Độ đo	XLM-R-B	XLM-R-L	PhoBERT-v2	PhoBERT-L	ViNeoBERT
UIT-ViQuAD	F1	0,7332	0,7792	0,7742	0,7798	0,7662
UIT-VSFC	F1-w	0,9281	0,9312	0,9345	0,9356	0,9284
UIT-VSMEC	F1-m	0,6145	0,3125	0,6415	0,6132	0,6163
UIT-ViCTSD	F1-m	0,7110	0,5759	0,7455	0,7526	0,7315
ViCoLA-syn	MCC	0,7827	0,4845	0,8103	0,7915	0,7789
XNLI (vi)	Acc	0,7541	0,8000	0,7720	0,7769	0,7714
ViANLI	F1-m	0,3625	0,1666	0,4529	0,3882	0,4273
QNLI (vi)	Acc	0,8592	0,8940	0,8872	0,8861	0,8791
UD-VTB (POS)	F1-m	0,7827	0,8062	0,7799	0,7879	0,8089
STS (vi)	Spearman	0,8226	0,8644	0,8557	0,8509	0,8392
Paraphrase	F1-m	0,9016	0,9437	0,9351	0,9400	0,9276
Retrieval	nDCG@10	0,1386	0,2565	0,4719	0,4659	0,4061
Reranking	MRR	0,5282	0,6741	0,8922	0,8794	0,8448

► Trung bình 13 tác vụ chỉ kém PhoBERT-large **0,9 điểm** – ở **3,5%** lượng token.

► **Vượt PhoBERT-large** ở 3/13: gán nhãn từ loại (dẫn đầu cả bảng), ViANLI, VSMEC.

► Cách biệt còn lại nằm ở truy hồi/xếp hạng – biểu diễn *cấp câu*, thứ cần nhiều dữ liệu nhất.

Mô hình	Token tiếng Việt	F1 ViQuAD
PhoBERT-large	~140 tỷ (40 lượt)	78,0
PhoBERT-base-v2	>140 tỷ	77,4
XLM-R-base	hàng trăm tỷ	73,3
ViNeoBERT	5 tỷ (1 lượt)	76,6

PhoBERT-large: ~140 tỷ token


ViNeoBERT: 5 tỷ (3,5%)

Con số đáng nói nhất

Với **3,5%** lượng token mà PhoBERT-large đã huấn luyện, ViNeoBERT đạt **98,3%** điểm F1 của mô hình đó – dù PhoBERT-large lớn gấp 1,5 lần về tham số.

- ▶ Xác nhận trực tiếp giả thuyết của khóa luận: *tái sử dụng* không gian biểu diễn cho phép kế thừa năng lực phần thân thay vì học lại từ đầu.
- ▶ Có ý nghĩa đặc biệt với các ngôn ngữ ít tài nguyên.

Biến trên 4.096 token thành năng lực dùng được



Hình: pseudo-perplexity theo độ dài chuỗi, trước và sau pha mở rộng ngữ cảnh

CPT chạy ở độ dài 1.024, sau đó thêm **~200 triệu token** (~4% ngân sách) ở độ dài 4.096.

Trước: ổn định tới ≈ 3.000 token rồi *giảm nhanh*.
Sau: phẳng quanh **2–3** trên toàn dải tới 4.096.

1. Giới thiệu
2. Cơ sở lý thuyết
3. Phương pháp đề xuất
4. Thực nghiệm và đánh giá
5. Kết luận và hướng phát triển

Đóng góp của khóa luận

- ▶ **ViNeoBERT** – Encoder hiện đại ≈ 250 triệu tham số cho tiếng Việt, kế thừa RoPE/SwiGLU/Pre-RMSNorm và trần ngữ cảnh 4.096 token.
- ▶ **Quy trình chuyển đổi ngôn ngữ** ba giai đoạn, lần đầu áp dụng cho một kiến trúc Encoder thể hệ mới.
- ▶ **Ba cải tiến so với SALT gốc**: điểm neo theo cặp dịch, khởi tạo riêng lớp đầu ra, giai đoạn căn chỉnh với thân đóng băng.
- ▶ **Bộ mã nguồn công khai** cùng toàn bộ kịch bản huấn luyện.

Kết quả chính

- ▶ **76,62** điểm F1 trên UIT-ViQuAD – hơn XLM-R-base 3,3 điểm.
 - ▶ Cao hơn XLM-R-base ở **11/12** tác vụ; dẫn đầu cả bảng ở gán nhãn từ loại.
 - ▶ Từng lựa chọn thiết kế đều được kiểm chứng có kiểm soát: $\gamma = 0,1$, khởi tạo riêng hai ma trận (67,52 so với 54,09), căn chỉnh với thân đóng băng (-26% perplexity).
 - ▶ Ngữ cảnh 4.096 token trở thành năng lực dùng được với chỉ ~ 200 triệu token bổ sung.
- ⇒ Tất cả đạt được với **3,5%** lượng token của PhoBERT-large.

Hạn chế

- ▶ **Ngân sách huấn luyện:** 5 tỷ token vẫn nhỏ; chưa vượt PhoBERT-base-v2 ở nhóm phân loại câu ngắn.
- ▶ **Phạm vi đánh giá:** chưa khảo sát nhận dạng thực thể có tên.
- ▶ **Ngữ cảnh dài:** mới kiểm chứng bằng độ đo nội tại (pseudo-perplexity), chưa có tác vụ ứng dụng.
- ▶ **Tokenizer:** kế thừa ViDeBERTa, chạy ở mức âm tiết trên văn bản thô – *không tách từ* như PhoBERT; ảnh hưởng của khác biệt này chưa được phân tích riêng.

Hướng phát triển

1. **Mở rộng ngân sách CPT** – đường cong F1 vẫn đang đi lên.
2. **Trộn lại 5–10% dữ liệu tiếng Anh** như cơ chế phát lại (replay) để giảm mất thông tin [Elhady et al., 2025].
3. **Đánh giá trên tác vụ ngữ cảnh dài** (hỏi đáp đa đoạn, truy xuất tài liệu); vượt trần 4.096 token bằng YaRN [Peng et al., 2023].
4. **Mở rộng bộ đánh giá** – NER, truy xuất quy mô lớn, lặp lại nhóm biểu diễn câu qua nhiều seed.
5. **Tổng quát hóa quy trình** sang ngôn ngữ ít tài nguyên khác và kiến trúc nền khác.

**Xin chân thành cảm ơn quý thầy cô
đã lắng nghe phần trình bày.**

Nhóm rất mong nhận được các ý kiến đóng góp của hội đồng.

- Bojanowski, P., Grave, E., Joulin, A., and Mikolov, T. (2017). Enriching word vectors with subword information. *Transactions of the Association for Computational Linguistics*, 5:135–146.
- Conneau, A., Khandelwal, K., Goyal, N., et al. (2020). Unsupervised cross-lingual representation learning at scale. In *Proceedings of ACL*, pages 8440–8451.
- de Vries, W. and Nissim, M. (2021). As good as new. how to successfully recycle English GPT-2 to make models for other languages. In *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*.
- Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*, pages 4171–4186.
- Dobler, K. and de Melo, G. (2023). FOCUS: Effective embedding initialization for monolingual specialization of multilingual models. In *Proceedings of EMNLP*.
- Elhady, A., Agirre, E., and Artetxe, M. (2025). Emergent abilities of large language models under continued pretraining for language adaptation. In *Proceedings of ACL*.
- Ethayarajh, K. (2019). How contextual are contextualized word representations? comparing the geometry of BERT, ELMo, and GPT-2 embeddings. In *Proceedings of EMNLP-IJCNLP*.
- Gao, J., He, D., Tan, X., Qin, T., Wang, L., and Liu, T.-Y. (2019). Representation degeneration problem in training natural language generation models. In *International Conference on Learning Representations (ICLR)*.
- Hu, S., Tu, Y., Han, X., He, C., Cui, G., Long, X., et al. (2024). MiniCPM: Unveiling the potential of small language models with scalable training strategies. *arXiv preprint arXiv:2404.06395*.
- Ibrahim, A., Thérien, B., Gupta, K., et al. (2024). Simple and scalable strategies to continually pre-train large language models. *Transactions on Machine Learning Research (TMLR)*.

- Junczys-Dowmunt, M., Grundkiewicz, R., Dwojak, T., et al. (2018). Marian: Fast neural machine translation in C++. In *Proceedings of ACL 2018, System Demonstrations*.
- Le Breton, L., Fournier, Q., El Mezouar, M., Morris, J. X., and Chandar, S. (2025). NeoBERT: A next-generation BERT. *arXiv preprint arXiv:2502.19587*.
- Lee, S., Hong, S., Moon, H., and Lim, H. (2025). Semantic aware linear transfer by recycling pre-trained language models for cross-lingual transfer. In *Findings of the Association for Computational Linguistics: ACL 2025*, pages 16180–16193.
- Levine, Y., Wies, N., Sharir, O., Bata, H., and Shashua, A. (2020). The depth-to-width interplay in self-attention. In *Advances in Neural Information Processing Systems (NeurIPS)*.
- Liu, Y., Lin, P., Wang, M., and Schütze, H. (2024). OFA: A framework of initializing unseen subword embeddings for efficient large-scale multilingual continued pretraining. In *Findings of the Association for Computational Linguistics: NAACL 2024*.
- Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., and Stoyanov, V. (2019). RoBERTa: A robustly optimized BERT pretraining approach. *arXiv preprint arXiv:1907.11692*.
- Martins, A. F. T. and Astudillo, R. F. (2016). From softmax to sparsemax: A sparse model of attention and multi-label classification. In *Proceedings of the 33rd International Conference on Machine Learning (ICML)*.
- Meister, C., Stokowiec, W., Pimentel, T., Yu, L., Rimell, L., and Kuncoro, A. (2023). A natural bias for language generation models. In *Proceedings of ACL*.
- Minixhofer, B., Paischer, F., and Rekabsaz, N. (2022). WECHSEL: Effective initialization of subword embeddings for cross-lingual transfer of monolingual language models. In *Proceedings of NAACL-HLT*, pages 3992–4006.
- Nguyen, D. Q. and Nguyen, A. T. (2020). PhoBERT: Pre-trained language models for Vietnamese. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 1037–1042.

- Nguyen, T., Nguyen, C. V., Lai, V. D., et al. (2024). CulturaX: A cleaned, enormous, and multilingual dataset for large language models in 167 languages. In *Proceedings of LREC-COLING*, pages 4226–4237.
- Ormazabal, A., Artetxe, M., Labaka, G., Soroa, A., and Agirre, E. (2019). Analyzing the limitations of cross-lingual word embedding mappings. In *Proceedings of ACL*, pages 4990–4995.
- Peng, B., Quesnelle, J., Fan, H., and Shippole, E. (2023). YaRN: Efficient context window extension of large language models. In *arXiv preprint arXiv:2309.00071*.
- Salazar, J., Liang, D., Nguyen, T. Q., and Kirchhoff, K. (2020). Masked language model scoring. In *Proceedings of ACL*, pages 2699–2712.
- Shazeer, N. (2020). GLU variants improve transformer. *arXiv preprint arXiv:2002.05202*.
- Su, J., Lu, Y., Pan, S., Murtadha, A., Wen, B., and Liu, Y. (2024). RoFormer: Enhanced transformer with rotary position embedding. *Neurocomputing*, 568.
- Tran, C. D., Pham, N. H., Nguyen, A., Hy, T. S., and Vu, T. (2023). ViDeBERTa: A powerful pre-trained language model for Vietnamese. In *Findings of the Association for Computational Linguistics: EACL 2023*, pages 1071–1078.
- Xiong, R., Yang, Y., He, D., Zheng, K., Zheng, S., Xing, C., Zhang, H., Lan, Y., Wang, L., and Liu, T.-Y. (2020). On layer normalization in the transformer architecture. In *Proceedings of the 37th International Conference on Machine Learning (ICML)*.
- Zhang, B. and Sennrich, R. (2019). Root mean square layer normalization. In *Advances in Neural Information Processing Systems (NeurIPS)*.